Christian Thomas

Humboldt-Universität zu Berlin, Institut für Kulturwissenschaft Projekt *Hidden Kosmos*, www.culture.hu-berlin.de/hidden-kosmos

Exposé zu einem Vortrag, angenommen für die DHd-Tagung 2015 "Von Daten zu Erkenntnissen: Digitale Geisteswissenschaften als Mittler zwischen Information und Interpretation", http://dhd2015.uni-graz.at/

- eingereicht am 10.11.2014, korrigierte Version vom 20.12.2014 -

Hidden Kosmos – Humboldts ,Kosmos-Vorträge' als Probe der Digital Humanities



Abstract

Im Projekt *Hidden Kosmos – Reconstructing Alexander von Humboldt's »Kosmos-Lectures«* (www.culture.hu-berlin.de/hidden-kosmos) der Humboldt-Universität zu Berlin (HU) werden seit Juni 2014 Quellen zu den sogenannten Kosmos-Vorträgen digitalisiert. Darin stellte Alexander von Humboldt 1827/28 in zwei teilweise parallel verlaufenden Vortragsreihen an der Berliner Universität und der benachbarten Singakademie das naturwissenschaftliche Wissen seiner Zeit dar.

Das Projekt *Hidden Kosmos* wird sämtliche bislang bekannte Hörernachschriften aus Bibliotheken, Archiven und Privatsammlungen in Deutschland, Polen und der Türkei virtuell zusammenführen. Insgesamt elf Nachschriften wurden bisher ermittelt, davon beziehen sich acht auf den 61-stündigen Universitäts-Zyklus, drei auf den nur 16 Vorträge umfassenden Singakademie-Zyklus. TEI-kodierte Transkriptionen der ca. 3500 Manuskriptseiten werden als standardkonform aufbereitetes, tief annotiertes und vielseitig vernetztes Volltextkorpus unter einer offenen Lizenz zur Verfügung gestellt. Damit wird auf einer umfassenden Quellenbasis die noch ausstehende, intensive Erforschung der Humboldtschen Vortragszyklen überhaupt erst ermöglicht.

Der Vortrag veranschaulicht anhand erster Ergebnisse des Forschungsprojekts dessen konzeptionelle Grundlagen. Um dem breiter angelegten Themenkreis der DHd-Tagung gerecht zu werden, wird dabei weitgehend von Humboldt-spezifischen Inhalten abstrahiert und der Fokus auf die Aufbereitung der Daten sowie auf die dabei zum Einsatz kommenden Methoden und Verfahren der 'Digital Humanities' (DH) gerichtet.

Korpusaufbau: Drei Wege der Volltexterstellung

Das zu bearbeitende Korpus umfasst insg. ca. 3500 Seiten aus elf handschriftlichen Nachschriften. Die Online-Publikation *Hidden Kosmos* soll jedes Dokument dieser vielstimmigen Überlieferung im Volltext wiedergeben, anstatt aus den voneinander abweichenden Nachschriften einen 'idealen' Text zu konstruieren. Dabei werden drei unterschiedliche Wege der Volltexterstellung verfolgt.

1) Kollation: Zwei der Nachschriften, je eine aus der Universität und der Singakademie, sind bereits als Druckausgaben erschienen (Anonym 1934, Hamel/Tiemann 1993; vgl. Literaturverzeichnis im Anhang). Der per OCR gewonnene und manuell korrigierte Volltext dieser Ausgaben wird mit der jeweiligen Vorlage verglichen. Die teilweise gravierenden, im Druck nicht vermerkten Abweichungen vom Manuskript – "Normalisierungen", "stillschweigende Korrekturen" sowie Transkriptionsfehler – werden in editorischen Kommentaren vermerkt.

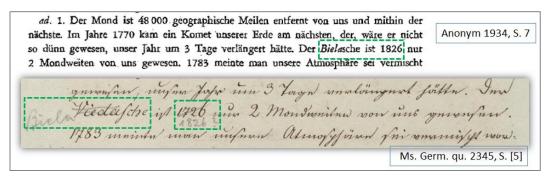


Abb. 1: ,Stillschweigende Korrekturen' gegenüber der handschriftlichen Vorlage in Anonym 1934.

| lich nur näher zusammenstehende Systeme von Sonnen, welches Milchstraßen sind, die wenigstens um 100 ihrer Dunstmassen von uns entfernt sind <i>Herschel</i> hat diese entfernten Milchstraßen am ganzen Himmel aufgesucht, und es sind davon bereits über 3000 entdeckt worden. | Hamel/Tie- mann (Hrsg.) 1993, S. 43 |
|--|---|
| Jingh mulfnundnu Willfolmer Inn y (Ms. Germ. qu. 2124, Bl. 2r) | |

Abb. 2: Transkriptionsfehler in Hamel/Tiemann 1993: "Dunstmassen" st. "Durchmesser".

Die Kollation der beiden Druckausgaben sowie einer späteren Abschrift eines Manuskripts mit ihren jeweiligen handschriftlichen Vorlagen ist abgeschlossen; die Texte werden zum Zeitpunkt der Konferenz über das Deutsche Textarchiv (DTA) der Berlin-Brandenburgischen Akademie der Wissenschaften (BBAW) und die HU verfügbar sein (s. Abschnitt Parallele Publikation). Jede der entstehenden Transkriptionen dokumentiert allein die Handschrift, die sie wiedergibt, d. h. Abweichungen der Manuskripte voneinander werden *nicht* innerhalb der Transkription vermerkt, sondern nach Fertigstellung der beiden Volltexte automatisch ermittelt und visualisiert. Im Vortrag werden die Vorzüge dieses DH-Verfahrens gegenüber dem 'klassischen' Variantenapparat dargestellt.

2) Texterfassung durch Dienstleister: Fünf der bislang nicht erfassten Nachschriften aus der Universität (insg. ~2600 Seiten) weisen ein größtenteils regelmäßiges Schriftbild und vergleichsweise wenige Ergänzungs- und Überarbeitungsspuren auf.

hellen Kern mit einer hichthille umgebin zeigen: in deiser Lichthille mint man Ab- and Junchmen (wahr, eine Ebbe

Abb. 3: Leichte Transkription: SBB-PK, Ms. Germ. qu. 1711, Bl. 2r

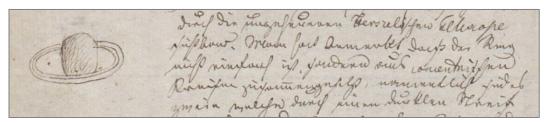


Abb. 4: Mittelschwere Transkription: Biblioteka Jagiellońska Kraków, Handschrift 6623 II, S. 144

Wenngleich es – anders als bei der Erfassung von Drucktexten – im Bereich handschriftlicher Überlieferung noch keine etablierte Praxis ist, lag es aus unserer Sicht nahe, diese Manuskripte durch einen Dienstleister erfassen zu lassen. Das wissenschaftliche/studentische Personal des *Hidden-Kosmos-*Projekts konzentriert sich auf die Qualitätssicherung, die tiefere Annotation, Kommentierung, intra- und intertextuelle Verknüpfung, (normdatengestützte) Referenzierung und Publikation der Volltexte. So kann trotz geringer Personalausstattung in nur zweijähriger Laufzeit die verhältnismäßig große Zahl von ca. 3500 Manuskriptseiten bewältigt werden.

Mit *textloop* wurde ein bei der Erstellung elektronischer Volltexte, insbesondere XML-annotierter Volltexte gemäß den Richtlinien der *Text Encoding Inititiative* (TEI) erfahrener Partner gefunden. *textloop* übernimmt die Texterfassung (Zeichengenauigkeit mind. 98%) samt Basisannotation, die entsprechende Einweisung und Anleitung der Texterfasser. Weiterhin ist *textloop* für die Erstellung und fortlaufende Anpassung des RNG-Schemas und der ODD-Dokumentation¹ nach den Bedürfnissen des Projekts verantwortlich.² Im Vortrag sollen unsere Erfahrungen mit dem externen Dienstleister dargestellt werden, auch, um Handschriften-Digitalisierungsvorhaben mit ähnlichen Beständen über die Möglichkeiten einer solchen Zusammenarbeit zu informieren.

3) Texterfassung durch Projektteam: Schließlich werden Nachschriften, die aufgrund des Schriftbilds und zahlreicher Überarbeitungsspuren für die Erfassung durch einen Dienstleister nicht geeignet sind, durch wissenschaftliches/studentisches Personal im Projekt transkribiert.



Abb. 5: Schwere Transkription: SBB-PK, Sla. Darmstaedter, F 2c 1853 Riess, Peter Theophil, S. 67

RNG = Relax NG, Regular Language for XML; vgl. http://relaxng.org/. ODD = One Document Does it All; vgl. http://www.tei-c.org/Guidelines/Customization/odds.xml. Vgl. auch TEI P5 Guidelines, Ch. 23: "Using the TEI", http://www.tei-c.org/release/doc/tei-p5-doc/en/html/USE.html, zum Einsatz von RNG und ODD.

Die Erfassung einer bisher unveröffentlichten, 800-seitigen Nachschrift aus der Universität wurde im November 2014 abgeschlossen; bis zum Zeitpunkt der Konferenz werden dieser und weitere von *textloop* erfasste Bände publiziert sein.

Annotation in TEI P5

Die Volltexterstellung erfolgt von Beginn an in TEI-XML, so dass bereits während der Transkriptionsarbeit die Basisannotation der Dokumente vorgenommen werden kann. Die Kodierung der Dokumente geschieht vollständig TEI-konform unter Verwendung des projekteigenen Schemas, eines TEI-Subsets *ohne* projektspezifische Erweiterungen. Das *Hidden-Kosmos-*Tagset folgt weitgehend dem Basisformat des Deutschen Textarchivs (DTABf), das eine minimale Anzahl an Tags für die konsistente Kodierung eines heterogenen Korpus definiert, um die größtmögliche Einheitlichkeit und Interoperabilität der darin enthaltenen Dokumente sicherzustellen (vgl. Haaf et al. forthcoming). Das DTABf-Tagset wurde für das *Hidden-Kosmos-*Projekt lediglich um Annotationsmöglichkeiten für Handschriften³ erweitert.

```
Jin Nofffiam it implies and form in the substantial of the substantial
```

Abb. 6: TEI-/DTABf-konforme Manuskript-Annotation; SBB-PK, Ms. Germ. qu. 2345, S. [11]

Orientierungspunkte für diese Erweiterung des Tagsets in Richtung Manuskript-Annotation boten die Encoding Guidelines der Nachwuchsgruppe Berliner Intellektuelle 1800–1830 der HU und das elaborierte "Genetic encoding" des Shelley-Godwin Archive. Das in dieser Weise erstellte *Hidden-Kosmos*-Tagset und das dazugehörige RNG-Schema stellt die einheitliche, TEI-konforme Kodierung sämtlicher Dokumente durch mehrere Bearbeiter auf Seiten des Dienstleisters und der Projektgruppe sicher.

Parallele Publikation

Das derart aufbereitete Korpus wird auf der projekteigenen *Hidden-Kosmos*-Webseite⁴ präsentiert. Die vielfältigen inhaltlichen Verbindungen der Kosmos-Vorträge zu anderen, bereits existierenden Online-Ressourcen machen eine Publikation der Daten auch auf anderen Plattformen wünschenswert – ein Desiderat, das sich auf etliche andere digitale Bestände übertragen ließe. Im Projekt *Hidden Kosmos* kann dies dank der interoperablen Kodierung der Dokumente in TEI-XML und der von Beginn an engen Kooperation mit verschiedenen Vorhaben realisiert werden.

Notwendig waren vor allem Erweiterungen um msDesc/<header>-Elemente sowie im <text>-Bereich um Elemente für Überschreibungen, Hinzufügungen über/unter/neben der Zeile, Schreiberwechsel etc.

Die Webseite befindet sich im Aufbau; zum geplanten Funktionsumfang siehe Abschnitt DH-Verfahren.

Die Re-Integration der für *Hidden Kosmos* vorgenommenen Erweiterungen in das DTABf-Tagset erlaubt die unmittelbare 'Parallelpublikation' der Nachschriften im DTA. Dort sind bereits mehrere Werke Humboldts, so der *Kosmos* (1845–62) und eine wachsende Zahl seiner unselbstständigen Schriften,⁵ sowie zahlreiche Werke seiner Zeitgenossen verfügbar.

Die linguistische Erschließung der Texte im DTA (inkl. automatischer Normierung historischer Schreibweisen) und die darauf basierende Suchmaschine ermöglichen eine optimale Nutzung der Nachschriften im Kontext der DTA-Korpora. Die Suchfunktion des DTA wird über eine Schnittstelle auch auf der *Hidden-Kosmos-*Webseite eingebunden, womit dort die Entwicklung einer eigenen (zwangsläufig basaleren) Volltextsuche nicht notwendig ist. Ein weiterer Vorzug der Publikation der Texte im DTA ist die Möglichkeit, die Dokumente mit Hilfe der webbasierten Qualitätssicherungs-Plattform DTAQ iterativ und möglichst kollaborativ zu optimieren: Transkriptions- und Auszeichnungsfehler können mit DTAQs Online-Editor direkt in der XML-Quelle behoben werden; ebenso können Normdaten-Referenzen für Personen- und Ortsnamen sowie weitere Verlinkungen und Kommentierungen vorgenommen bzw. ergänzt werden.

Als weitere Publikationsplattform dient das Projekt *Briefe und Texte aus dem intellektuellen Berlin um 1800*. Die Nachschriften der Kosmos-Vorträge werden dort den Vorlesungen F. A. Wolfs, Karl Solgers u. a. zur Seite gestellt. Der Datenaustausch wird durch die Orientierung beider Projekte am DTABf erleichtert.

Die jeweils aktuelle Version der XML-Basis im DTA dient als Referenzobjekt für alle weiteren Veröffentlichungsplattformen, deren Datenstand möglichst automatisiert mit der DTA-Version synchronisiert werden soll. Auf diese Weise lässt sich das Problem divergierender Versionen bei der "Spiegelung" von Daten auf verschiedenen Plattformen umgehen. Über das DTA bzw. das CLARIN-D-Repository der BBAW ist die Integration des Textkorpus in die web- und zentrenbasierte Forschungsinfrastruktur CLARIN-D gewährleistet, womit eine weitere Dissemination sowie die langfristige Archivierung und Bereitstellung der Daten sichergestellt wird.

DH-Verfahren

Neben den bereits beschriebenen DH-Verfahren und -Methoden⁶ bieten sich vor allem die in den DH inzwischen etablierten automatischen Kollationsverfahren für die Analyse des Korpus an. Diese dienen dazu, Ähnlichkeiten und Differenzen zwischen Textzeugen zu ermitteln und zu visualisieren.

Traditionellerweise, d. h. vor allem in Print-Editionen, werden Varianten zweier oder mehrerer Textzeugen in Kommentaren beschrieben und/oder in einem (notwendigerweise hochkomplexen) textkritischen Apparat ausgewiesen.⁷ Die automatische Kollation durch Programme wie *CollateX* und *juXta* macht die manuelle Auszeichnung von Varianten weitgehend überflüssig, ohne auf deren Mehrwert verzichten zu müssen.

Werke A. v. Humboldts im Deutschen Textarchiv siehe www.deutschestextarchiv.de/api/pnd/118554700.

⁶ Siehe dazu z.B. Reiche et al. 2014.

Deren Nutzung in der geisteswissenschaftlichen Forschungen ist wiederholt diskutiert worden; kürzlich wies Rüdiger Nutt-Kofoth auf der Tagung der AG germanistische Edition (vgl. Vanscheidt 2014) anhand von ca. 540 einschlägigen Fachartikeln nach, dass nur 40% die (historisch-)kritischen Editionen heranzogen, davon wiederum nur 10% die Erläuterungen der Ausgaben und *lediglich 5%* die Textvarianten zitierten. Demnach wird der am aufwendigsten herzustellende Editionsbestandteil am wenigsten genutzt.

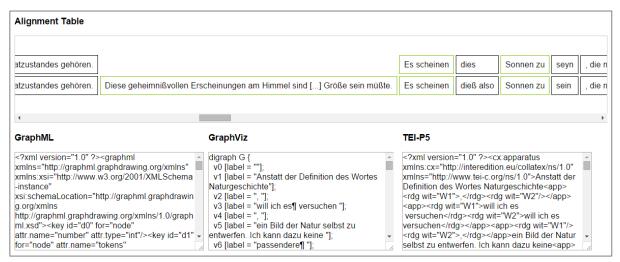


Abb. 7: CollateX Alignment Table: SBB-PK, Ms. Germ. qu. 2124 vs. Abschrift Hufeland, Privatbesitz C. Şengör.

Tabellarische Darstellungen wie die hier abgebildete, Variantengraphen, Parallelisierungen von Textzeugen (siehe Abb. 8 und 9 im Anhang) und "Critical Apparatus" bieten explorative Zugänge zu den unterschiedlichen Fassungen der Kosmos-Vorträge. Stets auf der aktuellen Version des Dokuments basierend, werden je nach Kollationsparameter Unterschiede auf der Ebene einzelner Zeichen, Worte und/oder ganzer Absätze sichtbar.

Die TEI-Annotation der Dokumente eröffnet noch weitere computergestützte Auswertungsmöglichkeiten: Die per <div type="session" n="[Zaehler]"> einheitlich annotierte Gliederung nach Vorlesungsstunden erleichtert dem Nutzer den Einstieg in parallele Lektüren der Nachschriften. Durch die Referenzierung von Personen und Orten kann direkt aus dem TEI ein normdatenbasiertes Gesamtregister aller Nachschriften generiert werden, was den systematischen Zugang zu den Quellen erleichtert. Eine Gesamtbibliographie der in den Vorträgen mit
bibl>-Tags versehenen Literaturangaben wird ein weiterer Zugangsweg zu den Kosmos-Vorträgen sein.

Ausblick

Über die beschriebene Nutzung als eigenständiges Forschungskorpus hinaus sollen die Nachschriften in einem Folgeprojekt als "Werkzeug" zur Erschließung der eigenhändigen Vortragsmanuskripte aus Humboldts Nachlass in der SBB-PK dienen. Die ursprünglichen Manuskripte wurden von Humboldt im Anschluss an die Vorträge während seiner Arbeit am *Kosmos* und anderen Publikationen stark überarbeitet und reorganisiert (vgl. Erdmann/Thomas 2014). Daher kann die im *Hidden-Kosmos*-Projekt angestrebte "Rekonstruktion" der Kosmos-Vorträge nicht aus Humboldts Manuskripten allein, sondern nur durch eine computergestützte Auswertung der umfangreichen Gesamtbasis aus Sekundärquellen (= Hörernachschriften) und Primärquellen (= Humboldts Vortragsnotizen) gelingen.

Abbildungen

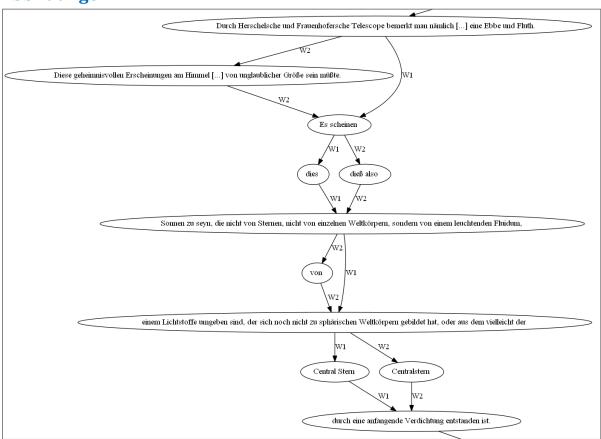


Abb. 8: CollateX Variant Graph (SBB-PK, Ms. Germ. qu. 2124 vs. Abschrift Hufeland, Privatbesitz C. Şengör)

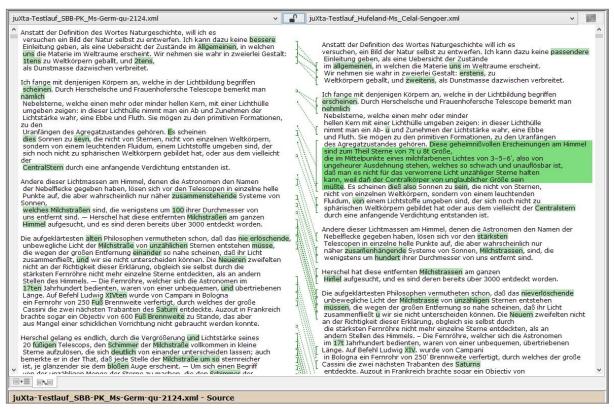


Abb. 9: *Juxta Side-by-Side view*

Bibliographie

Literatur

- Anonym (1934): Alexander von Humboldts Vorlesungen über physikalische Geographie nebst Prolegomenen über die Stellung der Gestirne. Berlin im Winter von 1827 bis 1828. Erstmalige (unveränderte)

 Veröffentlichung einer im Besitze des Verlages befindlichen Kollegnachschrift. Berlin: Miron Goldstein.
- Dove, Alfred (1872): "Alexander von Humboldt auf der Höhe seiner Jahre. (Berlin 1827–59.)", in: Bruhns, Karl (Hg.) (1872): Alexander von Humboldt: Eine wissenschaftliche Biographie. Leipzig: Brockhaus, 3 Bde, hier Bd. II., S. 93–484.
- Erdmann, Dominik und Christian Thomas (2010): Aussicht vom Zettelgebirge Zur Datenverarbeitung in Alexander von Humboldts Manuskripten der Kosmos-Vorlesungen. In: Trajekte 20 (2010), S. 30–36.
- Erdmann, Dominik und Christian Thomas (2014) »... zu den wunderlichsten Schlangen der Gelehrsamkeit zusammengegliedert«. Neue Materialien zu den ›Kosmos-Vorträgen‹ Alexander von Humboldts, nebst Vorüberlegungen zu deren digitaler Edition. In: HiN Humboldt im Netz. Internationale Zeitschrift für Humboldt-Studien (Potsdam Berlin) XV, 28, S. 34-45. Online verfügbar unter http://hin-online.de/hin28/erdmann-thomas.htm [zuletzt abgerufen 27.10.2014].
- Haaf, Susanne, Alexander Geyken and Frank Wiegand (2014/15): The DTA >Base Formatc: A TEI Subset for the Compilation of a Large Reference Corpus of Printed Text from Multiple Sources. To appear in: Journal of the Text Encoding Initiative (jTEI), Issue 8 [forthcoming].
- Hamel, Jürgen und Klaus-Harro Tiemann (Hg.) (1993): Alexander von Humboldt: Über das Universum. Die Kosmosvorträge 1827/28 in der Berliner Singakademie. Hrsg. von Jürgen Hamel u. Klaus-Harro Tiemann in Zusammenarbeit mit Martin Pape. Frankfurt a. M.: Insel.
- Harnack, Adolf (1900): Geschichte der Königlich Preussischen Akademie der Wissenschaften zu Berlin, Bd. I.2: Vom Tode Friedrichs des Großen bis zur Gegenwart. Berlin: Reichsdruckerei.
- Humboldt, Alexander von (1845–62): Kosmos. Entwurf einer physischen Weltbeschreibung. 5 Bände. Stuttgart (u.a.): Cotta. [Der Kosmos und weitere Schriften Alexander von Humboldts sind im Deutschen Textarchiv der BBAW verfügbar, siehe die Übersicht unter www.deutschestextarchiv.de/api/pnd/118554700 (zuletzt abgerufen 27.10.2014).]
- Nutt-Kofoth, Rüdiger (2014, bislang nicht publizierter Vortrag): "Wie werden Editionen für die literaturwissenschaftliche Interpretation genutzt? Versuch einer Annäherung aufgrund einer Auswertung neugermanistischer Periodika" auf der 15. internationalen Tagung der Arbeitsgemeinschaft für germanistische Edition "Vom Nutzen der Editionen", 19.–22.2.2014, Universität Aachen.
- Pierazzo, Elena (2011): "A Rationale of Digital and Documentary Editions." In: Literary and Linguistic Computing (LLC) 26(4), S. 463–77. doi:10.1093/llc/fqr033, http://llc.oxfordjournals.org/content/26/4/463 [zuletzt abgerufen 27.10.2014].
- Pierazzo, Elena (2014): "Digital Documentary Editions and the Others." In: Scholarly Editing: The Annual of the Association for Documentary Editing, 35 (2014), http://www.scholarlyediting.org/2014/essays/essay.pierazzo.html [zuletzt abgerufen 27.10.2014].
- Reiche, Ruth, Rainer Becker, Michael Bender, Matthew Munson, Stefan Schmunk und Christof Schöch:

 "Verfahren der Digital Humanities in den Geistes- und Kulturwissenschaften." (= DARIAH-DE Working Papers Nr. 4). Göttingen, 2014. URN: urn:nbn:de:gbv:7-dariah-2014-2-6,

 http://webdoc.sub.gwdg.de/pub/mon/dariah-de/dwp-2014-4.pdf.

Vanscheidt, Philipp (2014): Bericht zur Tagung "Vom Nutzen der Editionen", in: Scriptorium. Digitale Rekonstruktionen mittelalterlicher Bibliotheken, http://scriptorium.hypotheses.org/364.

Webressourcen [zuletzt abgerufen 28.10.2014]

Anne Baillot (ed.): "Briefe und Texte aus dem intellektuellen Berlin um 1800". Berlin: Humboldt-Universität zu Berlin, http://tei.ibi.hu-berlin.de/berliner-intellektuelle/;

Edition-specific TEI encoding guidelines, http://tei.ibi.hu-berlin.de/berliner-intellektuelle/encoding-guidelines.pdf.

CollateX, http://collatex.net/;

collateX Console, http://collatex.net/demo/.

Deutsches Textarchiv, http://www.deutschestextarchiv.de/;

DTABf: DTA-Basisformat, http://www.deutschestextarchiv.de/doku/basisformat;

DTAE: DTA-Erweiterungen, http://www.deutschestextarchiv.de/dtae;

DTAQ: Deutsches Textarchiv – Qualitätssicherung, http://www.deutschestextarchiv.de/dtaq/about.

Hidden Kosmos — Reconstructing Alexander von Humboldt's »Kosmos-Lectures«, http://www.culture.hu-berlin.de/hidden-kosmos.

Juxta Collation Software for Scholars, http://www.juxtasoftware.org/.

Shelley-Godwin Archive, http://shelleygodwinarchive.org/;

Encoding the S-GA, http://shelleygodwinarchive.org/about#encodingthesga.

Text Encoding Inititiative (TEI), http://www.tei-c.org/;

TEI: P5 Guidelines, http://www.tei-c.org/Guidelines/P5/.

textloop Martina Gödel, http://textloop.de/.